SEMINARIUM DYPLOMOWE · CZĘŚĆ II: PRAKTYKA

System przetwarzania danych oparty na pojedynczym oraz współpracujących modelach LLM

Implementacja, eksperyment i wstępne wyniki



Oliwier Komorowski · Jakub Nowak

PLAN

Plan dzisiejszej prezentacji

01

Założenia

Lokalnie, modele, sprzęt

02

Implementacja

Protokół debaty, kod

03

Eksperyment

Konfiguracje, benchmarki, metryki

04

Wyniki

Odpowiedzi na trzy pytania

PYTANIA BADAWCZE

Wracamy do trzech pytań badawczych

01

Czy debata dwóch modeli poprawia poprawność odpowiedzi względem pojedynczego modelu?

02

Czy ma znaczenie, że modele pochodzą od różnych twórców?

03

Jakim kosztem działa debata w stosunku do pojedynczego modelu?

ZAŁOŻENIA

Założenia projektu

01

Lokalnie

Modele uruchamiane przez Ollamę, bez chmury. Dane zostają na komputerze.

02

Otwarte wagi

Modele z biblioteki Ollamy, pobierane i uruchamiane lokalnie.

03

Jeden komputer

MacBook Pro, Apple M4 Pro, 24 GB pamięci zunifikowanej.

- Pamięć komputera wyznacza rozmiar modeli.

ZAŁOŻENIA

Dobór modeli

gemma4:12b

DALEJ: G

Twórca	**Google**
Parametry	**11,9 mld**
Kwantyzacja	**Q4_K_M**
W pamięci	**8,1 GB**

qwen3.5:9b

DALEJ: Q

Twórca	**Alibaba**
Parametry	**9,7 mld**
Kwantyzacja	**Q4_K_M**
W pamięci	**5,5 GB**

- Dwie rodziny, zbliżony rozmiar: razem 13,6 GB z dostępnych 24 GB.

IMPLEMENTACJA

Protokół debaty

Runda 0

Oba modele rozwiązują zadanie niezależnie (T = 0,05).



Odpowiedź końcowa

Runda debaty (1–3)

Każdy model widzi odpowiedź i uzasadnienie drugiego; może zmienić swoją (T = 0,1).

- Brak zgody po trzech rundach debaty kończy się wynikiem ABSTAIN.

IMPLEMENTACJA

Wyjście, zgodność, powtarzalność

FORMAT

Ustrukturyzowane wyjście

JSON wymuszony schematem Ollamy: **thought**, **final_answer**; w debacie także **agree**.

KONSENSUS

Sprawdzanie zgodności

Matematyka: normalizacja Hendrycksa, potem sympy. Medycyna: litera A-D.

USTAWIENIA

Powtarzalność

Seed 12345, thinking wyłączony, limit 6000 tokenów na odpowiedź, temperatura solo 0,1; debata 0,05 (runda 0) i 0,1 (rundy 1–3)

- Ta sama funkcja oceny dla solo i debaty, więc wyniki są porównywalne.

EKSPERYMENT

Pięć konfiguracji, dwie dziedziny

SOLO	SOLO	DEBATA	DEBATA	DEBATA
Q	G	Q + Q	G + G	Q + G

Matematyka	MATH-500 · 200 zadań
Medycyna	MedMCQA · 200 pytań

- Te same 200 zadań w każdej konfiguracji: porównania sparowane po task_id.

EKSPERYMENT

Benchmarki

MATEMATYKA

MATH-500

Podzbiór 500 zadań z benchmarku MATH, przygotowany przez OpenAI w pracy „Let's Verify Step by Step". Odpowiedź otwarta.

Użyto 200 pierwszych zadań (HuggingFaceH4/MATH-500, split test).

MEDYCYNA

MedMCQA

Ponad 194 tys. pytań medycznych z egzaminów wstępnych AIIMS i NEET PG: 21 przedmiotów, 2,4 tys. tematów. Cztery opcje.

Użyto 200 pierwszych pytań (openlifescienceai/medmcqa, split validation).

- Matematyka sprawdza rozumowanie, medycyna przede wszystkim wiedzę.

Źródła: huggingface.co/datasets/HuggingFaceH4/MATH-500; huggingface.co/datasets/openlifescienceai/medmcqa

EKSPERYMENT

Metryki

Ścisła trafność

Poprawne / 200. Abstain i null (brak odpowiedzi) liczone jako błąd (wrong).

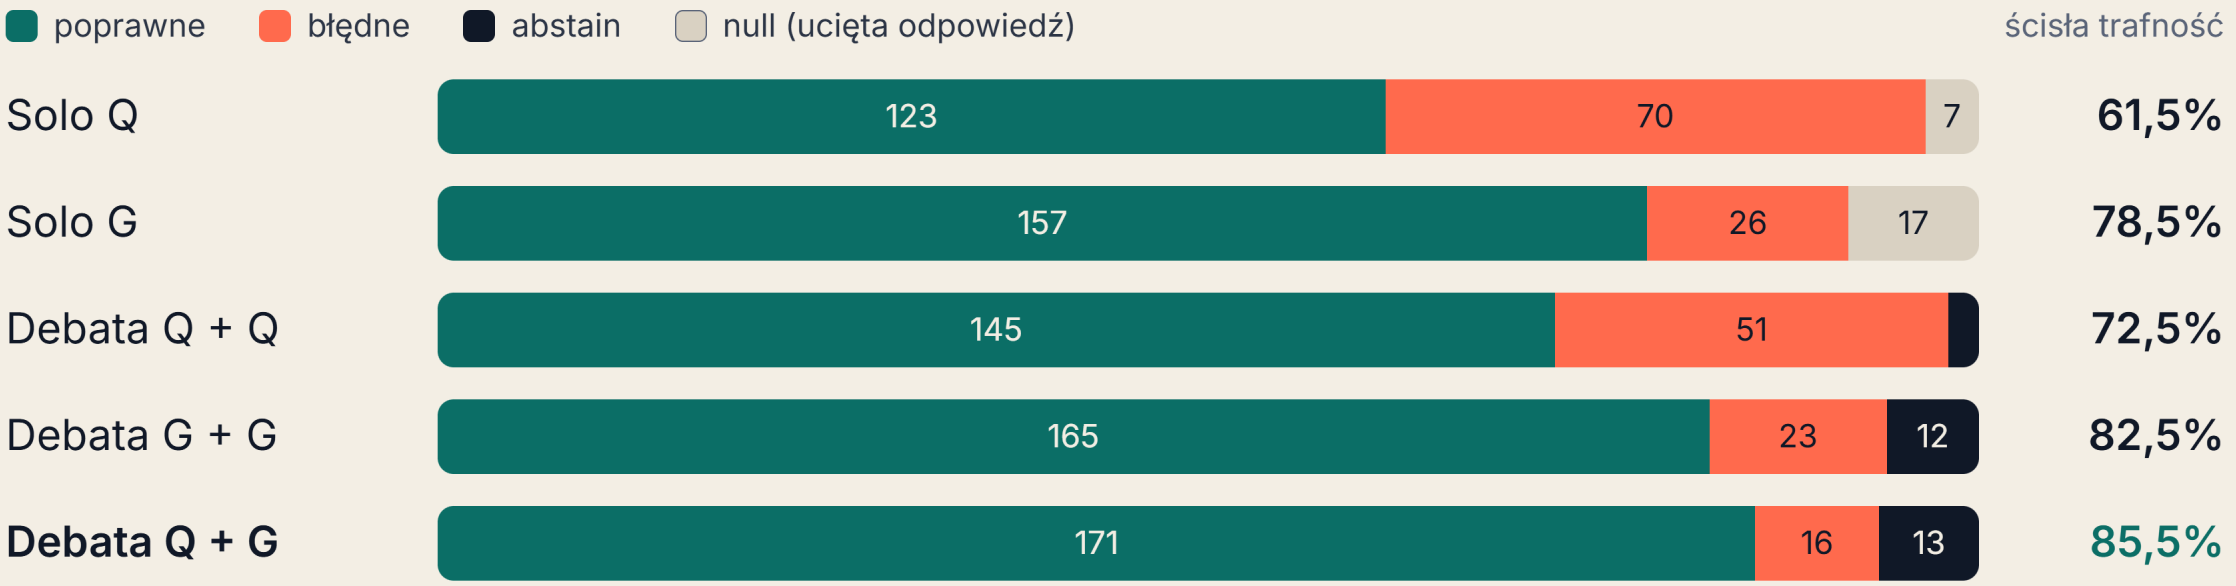
Pokrycie

Odsetek zadań, na które system w ogóle udzielił odpowiedzi.

Czas

Średnia i mediana czasu na zadanie [s], ten sam komputer.

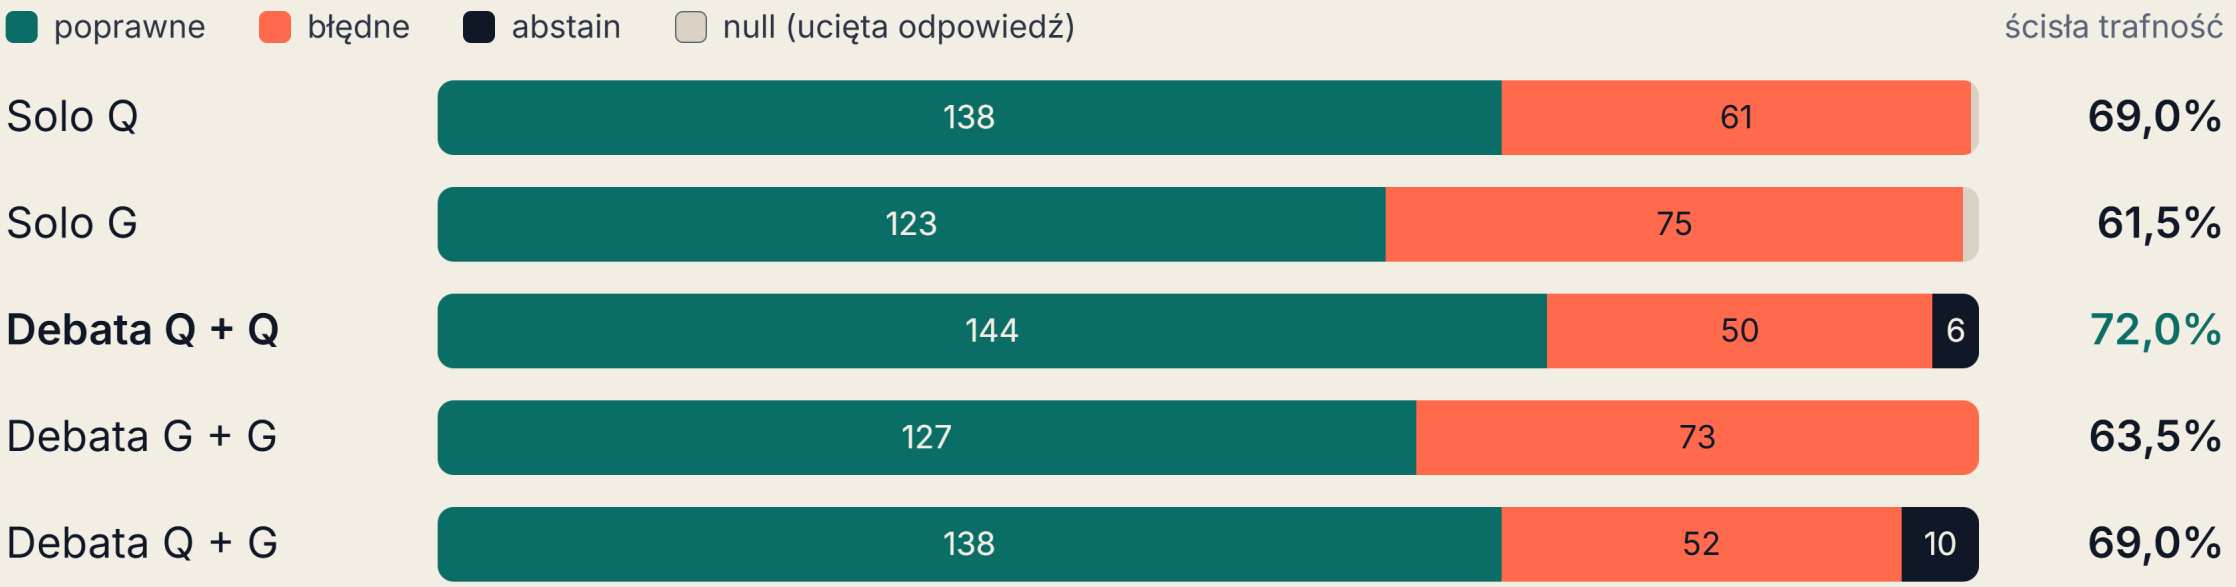
Wyniki: matematyka



- Każda debata wyżej niż solo jej modeli; najwyżej Q + G: 85,5%.

WYNIKI · MEDMCQA

Wyniki: medycyna



Najwyżej Q + Q: 72,0%. Q + G ma tyle samo co solo Q: 69,0%.

PYTANIE 1

Czy debata poprawia wynik?

Dziedzina	Debata vs najlepszy solo	Naprawione	Zepsute	w tym nulle solo*
Matematyka	Q + Q vs solo Q	25	3	3
Matematyka	G + G vs solo G	10	2	6
Matematyka	Q + G vs solo G	17	3	11
Medycyna	Q + Q vs solo Q	8	2	1
Medycyna	G + G vs solo G	7	3	0
Medycyna	Q + G vs solo Q	15	15	1

*W tym nulle solo: ile z naprawionych zadań to te, w których solo nie dało odpowiedzi (null, odpowiedź ucięta). Bez nich: G + G vs solo G 4 naprawione / 2 zepsute, Q + G vs solo G 6 / 3.

- Matematyka: tak, ale głównie przez naprawę nulli. Medycyna: nie.

PYTANIE 2

Czy różni twórcy mają znaczenie?

Dziedzina	Para	Zgoda w rundzie 0	Trafność: zgoda w rundzie 0	Trafność: po rundach 1–3
Matematyka	G + G	83%	90% (150/166)	68% (15/22)
Matematyka	Q + Q	74%	74% (109/148)	75% (36/48)
Matematyka	Q + G	57%	94% (107/114)	88% (64/73)
Medycyna	G + G	91,5%	67% (123/183)	24% (4/17)
Medycyna	Q + Q	88%	76% (134/176)	56% (10/18)
Medycyna	Q + G	64,5%	83% (107/129)	51% (31/61)

- Pary mieszane częściej się nie zgadzają, ale Q + G nie jest znacznie lepsza od G + G.

PYTANIE 3 · MATH-500

Koszt debaty: matematyka

Konfiguracja	Średnia [s]	Mediana [s]	× solo (śr. / med.)
Solo Q	13,5	5,8	—
Solo G	26,9	10,5	—
Debata Q + Q	54,6	13,3	4,0× / 2,3×
Debata G + G	121,7	21,5	4,5× / 2,0×
Debata Q + G	108,4	32,9	4,0× / 3,1×

MATEMATYKA

82%

czasu rozwiązywania zadań przypada na zadania, w których modele nie były zgodne w rundzie 0 (średnia z trzech par).

- Debata trwa średnio 4–4,5× dłużej niż najlepszy solo (mediana 2–3×).

PYTANIE 3 · MEDMCQA

Koszt debaty: medycyna

Konfiguracja	Średnia [s]	Mediana [s]	× solo (śr. / med.)
Solo Q	7,7	4,3	—
Solo G	8,3	5,9	—
Debata Q + Q	19,5	8,5	2,5× / 2,0×
Debata G + G	15,8	10,9	1,9× / 1,8×
Debata Q + G	33,4	18,6	4,3× / 4,3×

MEDYCYNA

49%

czasu rozwiązywania zadań przypada na zadania, w których modele nie były zgodne w rundzie 0 (średnia z trzech par).

- Debata trwa średnio 1,9–4,3× dłużej; najdroższa jest para mieszana Q + G.

PILOTAŻ THINKING

Tryb thinking: 10 zadań z matematyki

Konfiguracja	Poprawne	Błędne	Brak odpowiedzi	Śr. czas [s]
Solo Q	7	0	3 (null)	78,5
Solo G	4	0	6 (null)	130,7
Debata Q + Q	8	0	2 (abstain)	384,5
Debata Q + G	5	0	5 (abstain)	649,9
Debata G + G	4	0	6 (abstain)	901,6

Skąd braki?

W solo każdy null to odpowiedź ucięta limitem długości.

W debacie abstain: modele nie zgodziły się po 3 rundach.

- Każda udzielona odpowiedź poprawna, ale brak odpowiedzi stanowi 44% (22/50) odpowiedzi.

WSTĘPNE WNIOSKI

Odpowiedzi na trzy pytania

1 **Poprawność.** W matematyce debata pomaga, najmocniej słabszemu modelowi (Q + Q: 25 naprawionych, 3 zepsute). W medycynie brak istotnej poprawy.

2 **Różni twórcy.** Bez rozstrzygnięcia: pary mieszane częściej się nie zgadzają, ale pod względem jakości odpowiedzi Q + G nie wygrywa istotnie z G + G.

3 **Koszt.** Średnio ok. 2–4,5× dłużej niż najlepszy solo; większość czasu zużywają zadania bez zgody w rundzie 0.

TEZA Debata weryfikuje rozumowanie, ale nie dodaje brakującej wiedzy.