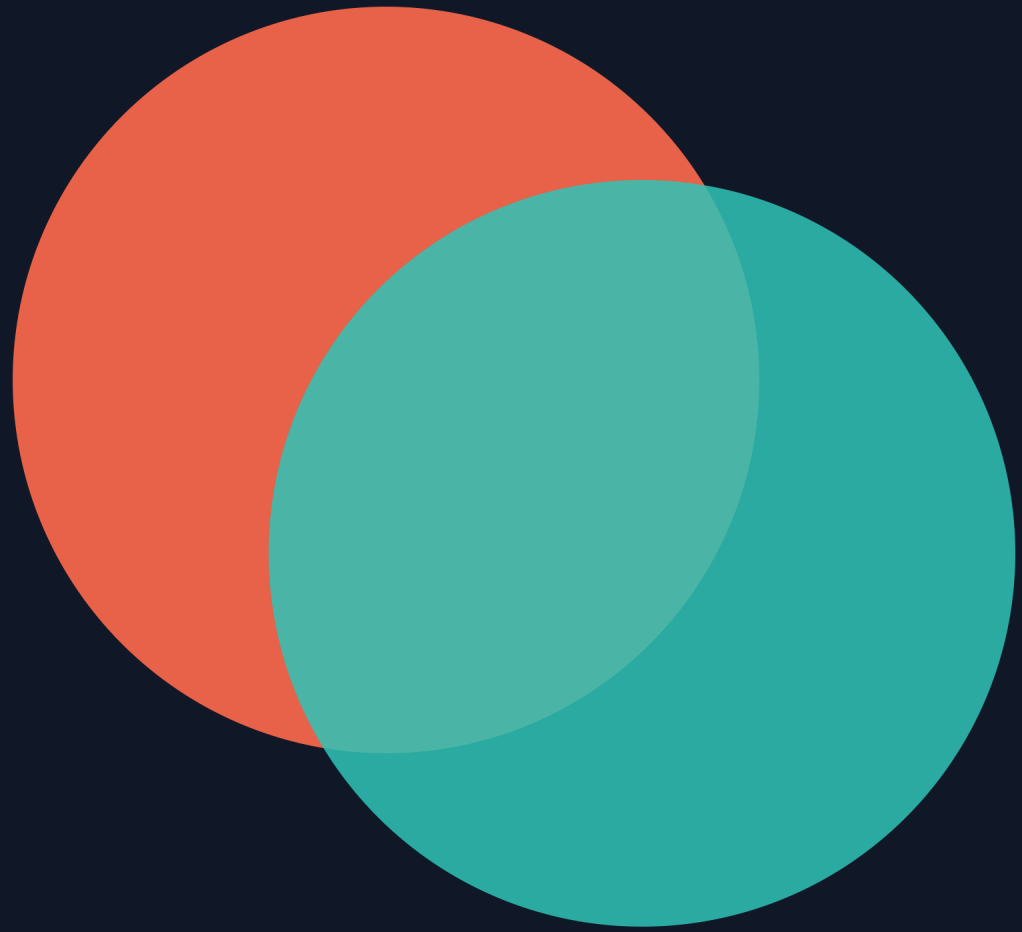
SEMINARIUM DYPLOMOWE · CZĘŚĆ I: TEORIA

System przetwarzania danych oparty na pojedynczym oraz współpracujących modelach LLM

Problem błędów i halucynacji oraz podstawy teoretyczne

Oliwier Komorowski · Jakub Nowak



PLAN

Cztery kroki od LLM do debaty

01

Czym są LLM

Generowanie, uczenie, skala

02

Problem

Błędy i halucynacje

03

Stan wiedzy

Prompting i debata

04

Badanie

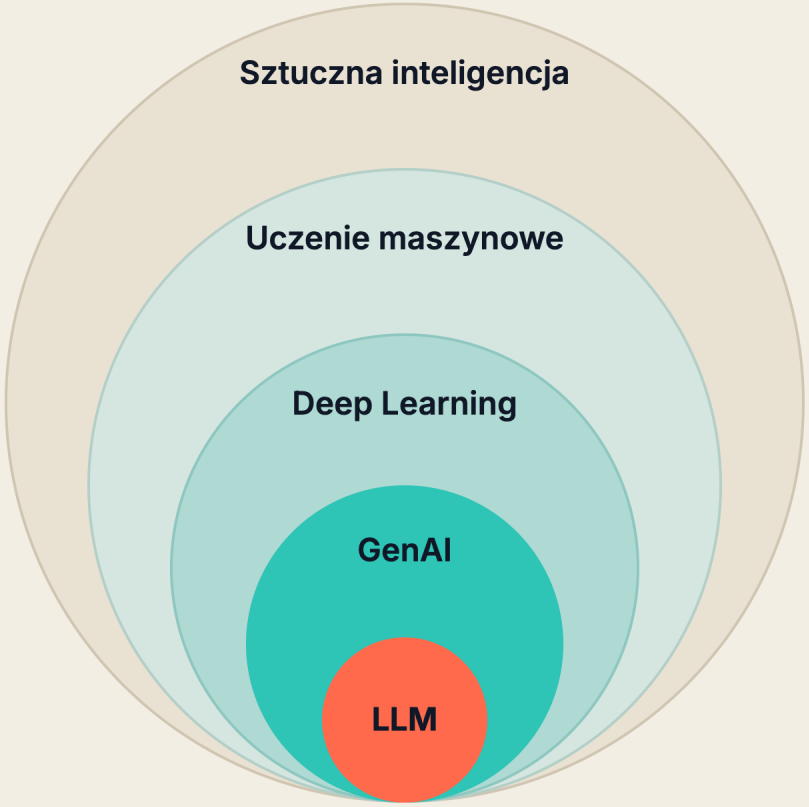
3 pytania

GŁÓWNE PYTANIE PRACY

Czy współpraca modeli działa lepiej niż pojedynczy model?

Punkt wyjścia: pojedynczy model jest autorem i jedynym recenzentem własnej odpowiedzi.

Od sztucznej inteligencji do LLM



GenAI wg Feuerriegel i in.

Techniki zdolne do generowania pozornie nowych, sensownych treści.

LLM to generatywne sieci neuronowe o miliardach parametrów, trenowane na tekście.

Ta praca dotyczy wyłącznie tekstu.

Źródło: Feuerriegel i in., Business & Information Systems Engineering, 2024

CZYM SĄ LLM

Generowanie to losowanie

p(token | kontekst)

Model nie szuka jednej poprawnej odpowiedzi. Losuje kolejny token z rozkładu prawdopodobieństwa.

- **Temperatura reguluje losowość**
- **Seed pozwala powtórzyć wynik**



Schemat poglądowy: długości słupków nie pochodzą z pomiarów.

CZYM SĄ LLM

Od treningu do promptu

KROK 1

Trening

Przewidywanie kolejnego tokenu na ogromnych zbiorach tekstu.

KROK 2

Dostrajanie

Wykonywanie poleceń i dopasowanie do preferencji ludzi, zamiast samego dokańczania tekstu.

UŻYCIE

Prompt

Rola, format odpowiedzi i kontekst nadawane bez zmiany wag.

Wynik to prawdopodobny tekst, a nie sprawdzona prawda.

PROBLEM

Halucynacje: dwa rodzaje

Treść brzmiąca wiarygodnie, lecz nieprawdziwa.

FACTUALITY

Fakty

Treść sprzeczna z weryfikowalną wiedzą o świecie.

FAITHFULNESS

Wierność

Odpowiedź odbiega od polecenia lub dostarczonego kontekstu.

Źródło: Huang i in., ACM Transactions on Information Systems, 2025

PROBLEM

Błędna odpowiedź brzmi tak samo pewnie jak poprawna.

Model losuje tokeny z wyuczonego rozkładu. Nie sprawdza treści z wiarygodnym źródłem, więc z samej formy nie widać, czy można mu ufać.

PROBLEM

Trzy źródła zawodności

01

Losowość

Ten sam prompt może dać różne odpowiedzi.

02

Brak samoweryfikacji

Autor odpowiedzi jest jej jedynym recenzentem.

03

Wrażliwość na prompt

Drobna zmiana formy polecenia zmienia odpowiedź.

PROBLEM

Stawka: matematyka i medycyna

Matematyka

- Jedna poprawna odpowiedź, którą da się sprawdzić
- Błąd w jednym kroku psuje cały wynik

Medycyna

- Błędna informacja może prowadzić do szkody
- Odpowiedź to wsparcie, nie źródło prawdy

Tu wiarygodność ma znaczenie.

STAN WIEDZY

Pierwsza linia obrony

PROMPTING

Instrukcje, kontekst, przykłady

Zmiana tekstu wejściowego zamiast ponownego trenowania modelu.

CHAIN-OF-THOUGHT

Kroki pośrednie

Rozumowanie krok po kroku zamiast samej odpowiedzi

Wciąż jedna ścieżka: błąd w środku przesądza o wyniku.

STAN WIEDZY

Od jednego modelu do wielu

STOPIEŃ 1

Jeden model

Jedna odpowiedź, bez kontroli.

STOPIEŃ 2

Głosowanie

Wiele odpowiedzi, wybór większością głosów.

STOPIEŃ 3

Wiele modeli

Role i podział pracy między modelami.

STOPIEŃ 4

Debata

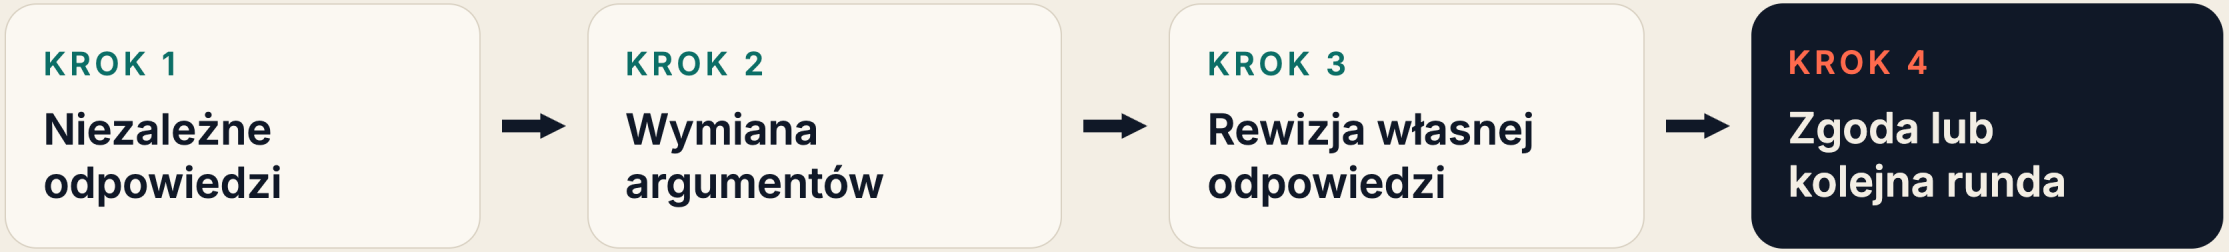
Modele wymieniają argumenty i poprawiają odpowiedzi.

Źródło: Tran i in., arXiv 2501.06322, 2025

STAN WIEDZY

Debata wielu modeli

Modele proponują odpowiedzi i przedstawiają rozumowanie, a następnie debatują przez kilka rund szukając wspólnej odpowiedzi.



Źródło: Du i in., arXiv 2305.14325, 2023

STAN WIEDZY

Dlaczego debata może działać

INTUICJA

Niezależne błędy

Różne modele mylą się w różnych miejscach. Zgodność niezależnych odpowiedzi jest pozytywnym sygnałem.

INTUICJA

Inny recenzent

Drugi model ocenia argumenty, a nie tylko wynik. Autor przestaje być jedynym sędzią.

LIANG I IN., 2023

Utknięcie przy własnej odpowiedzi

Pewny siebie model w samorefleksji nie szuka nowych rozwiązań, nawet gdy się myli. Drugi model może spojrzeć inaczej.

Źródło: Liang i in., arXiv 2305.19118, 2023

PYTANIA BADAWCZE

Co chcemy zbadać

1. Czy debata dwóch modeli poprawia poprawność odpowiedzi względem pojedynczego modelu?
2. Czy ma znaczenie, że modele pochodzą od różnych twórców?
3. Jakim kosztem działa debata w stosunku do pojedynczego modelu?

Część II: implementacja i wyniki

Źródła

Du i in. (2023). Improving Factuality and Reasoning in Language Models through Multiagent Debate. arXiv:2305.14325

Liang i in. (2023). Encouraging Divergent Thinking in Large Language Models through Multi-Agent Debate. arXiv:2305.19118

Huang i in. (2025). A Survey on Hallucination in Large Language Models. ACM Transactions on Information Systems

Feuerriegel i in. (2024). Generative AI. Business & Information Systems Engineering

Tran i in. (2025). Multi-Agent Collaboration Mechanisms: A Survey of LLMs. arXiv:2501.06322